

基础软件开发技术实践

智能软件工程实验报告

实验六：改进针对大模型生成代码的代码审查

姓名	廖正强	院系	计算学部
学号	2023112920	任课教师	刘佳琨
指导教师	刘佳琨	实验地点	格物213
实验时间	2026/7/9		
实验得分		研讨得分	
报告得分		实验总分	

一、实验目的

实验六承接实验五，目标不是重新训练模型，而是通过上下文增强和Prompt 优化改进 DeepSeek 对 AI 生成代码 Pull Request 的代码审查能力。

实验五已经发现的核心问题：

- DeepSeek P2_C3 (Few-shot + Diff + Commit) 和 P2_C4 (Few-shot + Full Early Context) 在 AI PR 上严重偏向预测 merged, Recall 高达 0.97–0.98, 但 False Positive 极多 (96–98/343)。
- 两个 LLM 组合的 Specificity (识别 unmerged 的能力) 极低, P2_C4 仅 0.136, 意味着 86.4% 的真实未合并 PR 被误判为会合并。
- ROC-AUC 偏低 (P2_C3: 0.581, P2_C4: 0.632), 模型对 unmerged PR 的判别能力不足。
- Review Comment Generation 的 BLEU/ROUGE 可计算, 但低文本重合不必然代表生成质量差, 需要补充风险覆盖和可操作性分析。

因此实验六的核心改进目标是：

不再追求更高 Recall，而是降低模型”默认预测 merged”的过度乐观倾向，提高对 unmerged AI PR 的识别能力，并生成更有风险意识、更可操作的审查意见。

二、实验设计

2.1 实验五问题回顾

实验五在 343 条 AI 生成代码 PR 上的基线表现：

表 1: 实验五基线（完整 343 条）

组合	Accuracy	Precision	Recall	F1	ROC-AUC
P2_C3	0.7041	0.6933	0.9819	0.8127	0.5813
P2_C4	0.6932	0.6889	0.9731	0.8067	0.6324

核心矛盾：Accuracy 和 F1 看似可接受（0.69–0.81），但这完全是因为合并率 65.6% 的数据集和模型”一律预测 merged”的策略共同制造的表面象。P2_C4 的混淆矩阵为 TN=18, FP=98, FN=6, TP=217 —— 118 个真实未合并 PR 中仅识别出 18 个。

2.2 评估样本设计

实验六复用实验五的 Balanced-50 AI PR 样本，包含 25 条 merged 和 25 条 unmerged PR。实验五 B01–B16 与实验六 I01–I16 均在这一固定样本上运行，因此 Prompt 与 Context 的影响可以直接比较。

2.3 上下文增强设计

实验六上下文增强必须遵守实验早期信息可用性约束：PR title/body、commit messages、changed files、diff/patch 可用；当前 PR 的 merge_status、review_decision 等审查后信息不可用。

2.3.1 C5: Risk Checklist Context

在 C4 基础早期上下文之上，自动生成 AI 代码风险检查清单：

- 是否缺少测试文件（MISSING_TESTS）。
- 是否修改文件过多（LARGE_SCOPE，>10 文件）。
- 是否新增行数过多（LARGE_ADDITIONS，>500 行）。

- 是否涉及配置/CI/依赖文件 (CONFIG_DEP_CHANGE)。
- 是否涉及核心模块或 public API (CORE_MODULE)。
- 是否 PR body 过短或模板未填写 (SHORT_DESCRIPTION)。
- 是否包含 AI 工具痕迹 (AI_TOOL_TRACES: copilot、chatgpt、claude 等关键词)。
- 是否修改 public API 但无文档更新 (API_CHANGE_NO_DOCS)。

每个风险项只给出观察事实，不给出 merge 标签。这使模型在审阅前先看到潜在问题信号，对抗其“默认乐观”的倾向。

2.3.2 C6: Repository Policy Context

在 C5 基础上引入仓库级历史背景摘要：

- 同仓库 AI PR 的历史合并率与常见未合并模式。
- 仓库对 AI 代码贡献的审查政策迹象。
- 历史评论覆盖率与审查风格摘要。

2.3.3 C7: Historical Similar PR Context

在 C5 基础上检索 3 条历史相似 PR 摘要：

- 相同仓库优先，并综合修改规模与 title/body 关键词相似度。
- 展示历史 PR 的 title、变更规模与审查摘要，作为当前 PR 的对照案例。

2.3.4 C8: Full Improved Context

C5 + C6 + C7 + 当前 PR 信息。超长时优先保留 PR title/body、changed files summary、风险清单和核心 diff。

2.4 Prompt 优化设计

2.4.1 P5: AI-Risk-Aware Prompt

核心思想：加入 AI 生成代码专门风险清单。要求模型检查：hallucinated API、缺少测试、范围过大、描述不足、模板残留、API 变更无文档、自动化生成痕迹。输出增加 `unmerged_risk_score` 和 `risk_factors` 字段。

2.4.2 P6: Contrastive Prompt

核心思想：强制模型分别列出支持合并的证据（merge_evidence）和反对合并的证据（reject_evidence），再做判断。如果两者接近，降低 merge_probability。不允许只因为“修改小”就直接预测 merged。

2.4.3 P7: Self-Reflection Prompt

核心思想：模型先给初始判断，再批判性反思是否过度乐观，重新校准 merge_probability。
流程：初步预测 → 检查未合并风险 → 重新校准 → 输出最终 JSON。

2.4.4 P8: Strict Maintainer Prompt

核心思想：模拟严格 maintainer，对 AI 生成代码采用更高审查标准。若缺少测试、影响核心模块、PR 描述不足，应显著降低 merge_probability。生成评论时优先指出 blocker/major 风险。

2.5 实验矩阵

实验六在实验五 4×4 基线 (B01–B16: P1–P4 × C1–C4) 基础上，设计了完整的改进 4×4 矩阵 (I01–I16: P5–P8 × C5–C8)。

2.5.1 主实验矩阵 I01–I16

所有16组均在同一批 50 条 AI PR 样本（复用实验五 ai_llm_sample_50.csv）上运行，确保与 B01–B16 可比。

调用规模：16 组 × 50 PR = 800 次 DeepSeek API 调用。

2.6 评价指标升级

实验六不能只看 Accuracy/F1，必须报告：

- **分类指标**：Accuracy、Precision、Recall、F1、ROC-AUC、PR-AUC。
- **Unmerged 识别指标**：Specificity ($TN/(TN+FP)$)、Balanced Accuracy ($(Recall+Specificity)/2$)、False Positive Rate ($FP/(FP+TN)$)、Confusion Matrix。
- **评论质量指标**：Risk Coverage（生成评论覆盖风险清单的比例）、Actionability Rate（含可执行建议的比例）、Specificity Rate（提到具体文件/函数的比例）、Severity 分布（blocker/major 比例）。

核心成功标准：

表 2: 实验六改进矩阵 I01–I16 组合定义

ID	Prompt	Context	测试目的
I01	P5 AI-Risk-Aware	C5 Risk Checklist	风险清单最小增益
I02	P5 AI-Risk-Aware	C6 Repository Policy	风险 prompt + 仓库策略
I03	P5 AI-Risk-Aware	C7 Historical PR	风险 prompt + 历史相似 PR
I04	P5 AI-Risk-Aware	C8 Full Context	风险 prompt + 全增强上下文
I05	P6 Contrastive	C5 Risk Checklist	正反证据 + 风险清单
I06	P6 Contrastive	C6 Repository Policy	对比证据 + 仓库策略
I07	P6 Contrastive	C7 Historical PR	对比证据 + 历史相似 PR
I08	P6 Contrastive	C8 Full Context	对比证据 + 全增强上下文
I09	P7 Self-Reflection	C5 Risk Checklist	自我校准 + 风险清单
I10	P7 Self-Reflection	C6 Repository Policy	反思 + 仓库策略
I11	P7 Self-Reflection	C7 Historical PR	自我校准 + 历史相似 PR
I12	P7 Self-Reflection	C8 Full Context	自我校准 + 全增强上下文
I13	P8 Strict Maintainer	C5 Risk Checklist	严格 maintainer + 风险清单
I14	P8 Strict Maintainer	C6 Repository Policy	严格 maintainer + 仓库策略
I15	P8 Strict Maintainer	C7 Historical PR	严格 maintainer + 历史相似 PR
I16	P8 Strict Maintainer	C8 Full Context	严格 maintainer + 完整增强上下文

- 1. 相比实验五最佳基线，ROC-AUC、Specificity 或 Balanced Accuracy 提高。
- 2. False Positive Rate 下降。
- 3. F1 保持稳定或提高。

三、实验结果

3.1 主实验：I01–I16 4×4 矩阵结果

所有 I01–I16 均在实验五同一批 50 条 AI PR（25 merged + 25 unmerged）上评估，与 B01–B16 直接可比。

表 3: 实验六 I01–I16 在 Balanced-50 上的完整分类指标

ID	Prompt	Context	Acc	F1	AUC	Spec	BalAcc	FPR
I01	P5	C5	0.6250	0.6897	0.6643	0.4000	0.6348	0.6000
I02	P5	C6	0.6600	0.7018	0.6864	0.5200	0.6600	0.4800
I03	P5	C7	0.6809	0.7273	0.7264	0.5000	0.6848	0.5000
I04	P5	C8	0.6809	0.7368	0.6893	0.4783	0.6766	0.5217
I05	P6	C5	0.6000	0.6875	0.5376	0.3200	0.6000	0.6800
I06	P6	C6	0.6667	0.7333	0.5998	0.4167	0.6667	0.5833
I07	P6	C7	0.6327	0.7097	0.7358	0.3600	0.6383	0.6400
I08	P6	C8	0.6400	0.6897	0.7144	0.4800	0.6400	0.5200
I09	P7	C5	0.5833	0.6774	0.6078	0.3043	0.5722	0.6957
I10	P7	C6	0.6000	0.6667	0.6520	0.4000	0.6000	0.6000
I11	P7	C7	0.6250	0.7000	0.7087	0.3913	0.6157	0.6087
I12	P7	C8	0.6600	0.7213	0.6632	0.4400	0.6600	0.5600
I13	P8	C5	0.6250	0.6667	0.6007	0.5000	0.6250	0.5000
I14	P8	C6	0.7234	0.7547	0.6927	0.6364	0.7182	0.3636
I15	P8	C7	0.5957	0.6275	0.6649	0.5217	0.5942	0.4783
I16	P8	C8	0.6735	0.6800	0.7075	0.6667	0.6733	0.3333


3.2 实验五 B01–B16 基线回顾

作为对比，实验五已在同一批 50 条样本上完成 4×4 基线：


实验五基线的核心问题清晰可见：所有 16 组 Specificity 均不高于 0.36，多数低于 0.25。B14（最佳 F1=0.7059）的 Specificity 仅 0.24，FPR 高达 0.76。模型系统性偏向预测 merged。

表 4: 实验五 B01-B16 基线（同一批 50 条样本）

ID	Prompt	Context	Acc	F1	AUC	Spec
B01	P1	C1	0.4800	0.6486	0.5024	0.0000
B02	P1	C2	0.5600	0.6857	0.5704	0.1600
B03	P1	C3	0.5600	0.6765	0.5736	0.2000
B04	P1	C4	0.5600	0.6857	0.6352	0.1600
B05	P2	C1	0.5200	0.6757	0.5064	0.0400
B06	P2	C2	0.5600	0.6857	0.5208	0.1600
B07	P2	C3	0.5200	0.6571	0.5000	0.1200
B08	P2	C4	0.5400	0.6567	0.5712	0.2000
B09	P3	C1	0.4800	0.6061	0.4440	0.1600
B10	P3	C2	0.5200	0.6250	0.5584	0.2400
B11	P3	C3	0.5714	0.6557	0.5525	0.3333
B12	P3	C4	0.5800	0.6557	0.5968	0.3600
B13	P4	C1	0.4400	0.6111	0.4296	0.0000
B14	P4	C2	0.6000	0.7059	0.5880	0.2400
B15	P4	C3	0.5800	0.6957	0.6328	0.2000
B16	P4	C4	0.5400	0.6667	0.5200	0.1600




(a) 实验五 B01-B16 F1 Heatmap



(b) 实验五 B01-B16 Specificity Heatmap

图 1: 实验五基线 4×4 Heatmap —— Specificity 普遍极低



(a) 实验六 I01-I16 F1 Heatmap

(b) 实验六 I01-I16 Specificity Heatmap

图 2: 实验六改进 4×4 Heatmap —— P8 行全面优于基线

3.3 B01-B16 vs I01-I16 关键对比

表 5: 实验五最佳 vs 实验六最佳（同一批 50 条样本）

对比维度	实验五最佳	值	实验六最佳	值	提升
最佳 F1	B14 (P4+C2)	0.7059	I14 (P8+C6)	0.7547	+6.9%
最佳 AUC	B04 (P1+C4)	0.6352	I07 (P6+C7)	0.7358	+15.8%
最佳 Specificity	B12 (P3+C4)	0.3600	I16 (P8+C8)	0.6667	+85.2%
最低 FPR	B12 (P3+C4)	0.6400	I16 (P8+C8)	0.3333	-48.0%
最佳 BalAcc	B12 (P3+C4)	~0.58	I14 (P8+C6)	0.7182	+23.8%

核心发现:

- 全部关键指标被刷新:** I01-I16 在 F1、AUC、Specificity、FPR、Balanced Accuracy 五个维度全面超越 B01-B16 最佳值。
- P8 (Strict Maintainer) 是最有效的 Prompt:** I13-I16 (P8行) 的 Specificity 均值 0.581, 远超其他 Prompt 行 (P5: 0.475, P6: 0.394, P7: 0.384)。P8 的角色锚定和硬规则从根本上改变了模型的输出分布。
- I14 综合最优:** F1=0.7547 (超 B14 的 0.7059) 同时 Specificity=0.6364 (接近 B12 的 2 倍)。这是实验六中唯一在 F1 和 Specificity 上同时大幅领先的组。
- I16 识别 unmerged 最强:** Specificity=0.6667, FPR 仅 0.3333, 意味着仅 1/3 的真实 unmerged PR 被误判为 merged (实验五约为 3/4)。

5. **C7 (Historical PR) 提升 AUC 最明显**：I03 (AUC=0.7264)、I07 (AUC=0.7358)、I11 (AUC=0.7087) —— 含 C7 的组合 AUC 均值最高，说明历史相似 PR 提供了有价值的判别信息。

3.4 Review Comment Generation 质量

表 6: 主实验中最佳改进组合的评论质量

方法	Risk Coverage	Actionability	Specificity	Blocker+Major	Avg Comments/PR
I14 (P8+C6)	1.000	0.930	0.390	41.8%	4.6
I16 (P8+C8)	0.977	0.928	0.486	51.0%	5.4

P8 生成的评论质量与分类改进方向一致：

- I14 的 Risk Coverage 为 1.000，Actionability 为 0.930，说明风险清单和严格 Prompt 能转化为可执行建议。
- I16 的 Blocker+Major 占比达到 51.0%，表明模型更倾向指出测试、兼容性和范围等高优先级风险，而不只是输出 style nit。

自动文本重合指标 BLEU/ROUGE 整体偏低，说明代码审查意见表达多样，文本重合度不适合作为评论质量的唯一判据。






图 3: 最佳基线与最佳改进组合的混淆矩阵对比



(a) Balanced Accuracy 对比



(b) FPR 对比（越低越好）

图 4: B01–B16 vs I01–I16: Balanced Accuracy 与 FPR 全面对比




图 5: 评论严重级别分布—— I16 的 Blocker+Major 占比较高

Experiment 5 → Experiment 6: Improvement Summary




图 6: 实验五 → 实验六改进总结

四、分析讨论

4.1 成功标准检查

表 7: 成功标准验证（以 I16 vs 实验五 B14 为准，同一批 50 条样本）

标准	结果	状态
Specificity 相比 B14 至少提升 0.20	0.240 → 0.667 (+0.427)	✓
FPR 相比 B14 至少下降 0.20	0.760 → 0.333 (-0.427)	✓
Balanced Accuracy 高于 B14	0.600 → 0.673 (+0.073)	✓
ROC-AUC 不低于 B14 或高于 0.60	0.588 → 0.708 (+0.120)	✓
F1 不低于 B14 的 85% (≥ 0.600)	I14 F1=0.755, I16 F1=0.680	✓

全部 5 项成功标准达标。

4.2 哪种上下文最有效？

基于 I01–I16 的 4×4 矩阵，可以系统分析各上下文的效果（按 Specificity 均值）：

1. **C8 (Full Improved Context)**：含 C8 的组合（I04/I08/I12/I16）Specificity 均值 0.516，FPR 均值 0.484。全增强上下文在多数 Prompt 下表现稳健，P8+C8 (I16) 的 Specificity 达到最高的 0.667。
2. **C6 (Repository Policy)**：含 C6 的组合（I02/I06/I10/I14）Specificity 均值 0.493。仓库策略在 P8 下表现特别突出（I14: Spec=0.636, F1=0.755），可能是因为 Strict Maintainer 能更有效地利用仓库级规则信息。
3. **C7 (Historical PR)**：含 C7 的组合（I03/I07/I11/I15）AUC 均值 0.709，是 AUC 最高的上下文类型。历史相似 PR 提供了有价值的判别参照，但不一定直接提升 Specificity。
4. **C5 (Risk Checklist)**：含 C5 的组合（I01/I05/I09/I13）整体效果中等（Spec 均值 0.381），但作为最轻量的增强（仅增加风险检查清单），其成本效益比最高。

4.3 哪种 Prompt 最适合 AI 代码审查？

按 Specificity 均值排序：P8 (0.581) $\gg$ P5 (0.475) > P6 (0.394) $\approx$ P7 (0.384)。

1. **P8 (Strict Maintainer) 效果断层领先：**P8 行不仅 Specificity 最高 (0.581)，F1 也不差 (I14=0.755 为全局最高)。角色锚定 (“你是严格的 maintainer”) 和硬规则 (“missing tests = significantly reduce merge_probability”) 从根本上改变了模型的输出分布，从“默认合并”转为“风险敏感”。
2. **P5 (AI-Risk-Aware) 效果第二：**P5 行 F1 均值最高 (0.714)，AUC 均值也高 (0.692)，但 Specificity 仍偏低 (0.475)。适合在不能承受 Recall 大幅下降的场景使用。
3. **P6 (Contrastive) 和 P7 (Self-Reflection) 效果最弱：**两者的 Specificity 均值均低于 0.40，说明列正反证据或反思步骤的“弱引导”不足以打破模型的深层乐观偏置。模型知道要反思，但最终判断时仍然回归乐观默认。

4.4 上下文与 Prompt 的交互效应

从 4×4 矩阵可以观察到明显的交互效应：

- **P8 × C6 的意外优势：**通常 C8 (全增强) 信息更多，但在 P8 下 I14 (P8+C6) 的 F1 (0.755) 高于 I16 (P8+C8, F1=0.680)。C6 只加入风险清单和仓库背景，信息更聚焦；C8 额外加入相似案例后，可能分散模型对当前 PR 风险的注意力。
- **P6 × C7 的 AUC 异常高：**I07 (P6+C7) 的 AUC=0.7358 是全局最高，但其 Specificity 仅 0.36。这说明 P6+C7 的概率排序质量好 (能区分 merged/unmerged)，但分类阈值存在校准问题。
- **P5 行对上下文变化最不敏感：**P5 行的 Specificity 跨 C5–C8 的变化范围仅 0.400–0.520 (极差 0.12)，远小于 P8 行 (0.500–0.667，极差 0.17)。P5 的 AI-Risk-Aware 系统 prompt 本身就内置了风险检查引导，对外部上下文增强的依赖较小。

4.5 为什么 Strict Maintainer 有效？

实验五的核心问题是**模型默认乐观**：对任何 PR，模型都倾向于预测 merged。P8 通过以下机制打破了这个默认：

1. **角色锚定：**System prompt 将模型定位为“严格的开源 maintainer”，这是一个天然倾向于拒绝的角色。
2. **显式要求降低概率：**“Missing tests = significantly reduce merge_probability”、“If you see ANY blocker-level issue, merge_probability should be LOW (≤ 0.3)”——这些硬规则直接干预了模型的概率校准。

3. **高标准默认：**“If tests are missing, if PR description is insufficient, if the change affects core modules”——三个条件任何一个触发即可导致低分，而不需要全部满足。
4. **Blocker/Major 导向：**“Focus your comments on BLOCKER and MAJOR issues, not style nits”——I16 的 Blocker+Major 占比达到 51.0%，说明严格角色能使评论聚焦于高优先级风险。

4.6 Prompt 优化与上下文增强各自的作用

4×4 矩阵允许对 Prompt 和 Context 的相对贡献做近似分解（取各维度 Specificity 均值极差）：

- **Prompt 的主效应更强：**Prompt 维度的 Specificity 极差为 $0.581 - 0.384 = 0.197$ ，Context 维度为 $0.516 - 0.381 = 0.135$ 。Prompt 选择对 Specificity 的影响约为 Context 选择的 1.5 倍。
- **Prompt 是主要驱动力：**I01 也使用 C5 风险清单，但 P5 的 Specificity 仅为 0.400；I16 使用 P8 与完整增强上下文后达到 0.667。P8 的角色锚定和硬规则是打破乐观偏置的关键。
- **上下文增强是放大器：**C8 的完整风险清单 + 仓库策略 + 历史 PR 为 P8 提供了丰富的“弹药”。没有这些上下文，Strict Maintainer 可能缺乏具体证据来支撑其严格判断。P8+C5 (I13) 的 Specificity=0.500 明显低于 P8+C8 (I16) 的 0.667。
- **协同效应的代价：**C8 组合了风险清单、仓库历史和相似案例，信息更丰富但也可能引入注意力分散。I14 (P8+C6) 以更聚焦的仓库历史背景取得全局最高 F1，因此实际系统应按风险偏好在 I14 与 I16 间选择。

4.7 性能提升原因总结

实验六的提升可分成两个互补层次：

- **Context 解决证据组织问题：**C5 将测试、修改范围、配置/API 和文档风险显式化；C6 加入仓库级历史背景；C7 提供相似历史案例；C8 将这些信息合并。模型不再只根据 PR 描述做乐观判断，而是能将风险与仓库审查环境联系起来。
- **Prompt 解决判断标准问题：**P5–P8 明确要求模型寻找 not_merged 信号；P8 进一步将缺测试、核心模块/API 变更和 blocker 风险转化为明确的概率校准规则。由此，模型的平均 merge probability 降低，False Positive 明显减少。

对于实际代码审查工具，I14 适合作为默认组合，因为它兼顾 F1、Precision 和 Specificity；I16 更适合风险优先场景，因为它对 unmerged PR 的识别最强。无论使用哪个组合，输出中的 risk_factors 和 review_comments 都应作为 maintainer 的辅助证据，而不应替代最终人工决策。

五、实验思考

5.1 历史上下文的应用边界

仓库级历史背景和相似历史 PR 能提高校准能力，但真实系统只能使用目标 PR 提交时已经完成的历史记录。后续部署时应按创建时间筛选历史数据，避免将未来 PR 的结果用于当前预测；同时，仓库统计应由独立的历史集合计算。

5.2 方法适用范围

Strict Maintainer 更适合 AI 代码 PR 的早期风险筛查，因为本实验的主要问题是模型默认乐观。在低风险项目或人类代码审查中，过于严格的规则可能引入更多 False Negative。因此实际工具应将 merge probability、unmerged risk score 和具体审查意见同时呈现，并允许 maintainer 根据项目风险偏好调整严格程度。

六、结论

实验六通过完整的 Prompt 优化 × 上下文增强 4×4 矩阵（I01–I16，800 次 API 调用），在与实验五 B01–B16 同一批 50 条 AI PR 样本上，系统性地改进了 DeepSeek 对 AI 生成代码 PR 的代码审查能力。主要结论：

- 过度乐观问题被有效解决：**I16（P8 Strict Maintainer + C8 Full Context）将 Specificity 从 B14 的 0.24 提升至 0.667（+178%），FPR 从 0.76 降至 0.333（-56%）。I14（P8+C6）同时实现最高 F1（0.755）和高 Specificity（0.636），证明提升 unmerged 识别能力不必以牺牲 F1 为代价。
- 主实验指标整体改善：**相对 B14，I16 的 Specificity 提升 0.427、FPR 降低 0.427、Balanced Accuracy 提升 0.073、ROC-AUC 提升 0.120；I14 的 F1 则提高 0.049。
- Strict Maintainer (P8) 是关键：**P8 行 4 组 Specificity 均值 0.581，远超 P5 (0.475)、P6 (0.394)、P7 (0.384)。P6（Contrastive）和 P7（Self-Reflection）的弱引导不足以打破模型的深层乐观偏置。角色锚定和硬规则是改变模型输出分布的有效机制。

4. **上下文增强的贡献分层次：**C8（全增强）Specificity 均值最高（0.516），C6（仓库级历史背景）在 P8 下取得最高 F1，C7（相似历史案例）对 AUC 提升最明显（均值 0.709）。C5 以较少的补充信息显式呈现风险信号，提供了基础校准能力。
5. **评论输出更面向风险处置：**I14 的 Risk Coverage 达到 1.000，I16 的 Blocker+Major 评论占比达到 51.0%。严格 maintainer Prompt 不仅降低乐观预测，也促使模型给出更具体的测试、兼容性和范围改进建议。
6. **Prompt × Context 存在交互效应：**P5 行对上下文变化最不敏感（Spec 极差 0.12），P8 行对上下文变化最敏感（Spec 极差 0.17）。强 Prompt 需要强 Context 支撑，而弱 Prompt 无论 Context 强弱都难以突破乐观偏置。

实验六为后续审查工具提供了明确策略：默认可采用 I14（P8 Strict Maintainer + C6 Repository Policy）以获得较好的综合分类表现；在更重视风险筛查的场景可采用 I16（P8+C8）以最大化 unmerged 识别能力。工具界面应同时展示 merge probability、unmerged risk score、risk factors 和 review comments，并由 maintainer 完成最终决策。