

基础软件开发技术实践

智能软件工程实验报告

实验七：命令行智能代码审查工具

姓名	廖正强	院系	软件学院
学号	2023112920	任课教师	刘佳琨
指导教师	刘佳琨	实验地点	格物 213
实验时间	2026 年 7 月 10 日		
实验得分		研讨得分	
报告得分		实验总分	

一、实验目的

完成本实验后，学生应能够：

1. 理解代码审查工具从算法验证到工程部署的完整过程。
2. 掌握前后端分离架构下模型服务的设计与实现。
3. 能够将已有的机器学习、深度学习及大语言模型封装为统一 HTTP 接口。
4. 能够设计命令行交互界面，实现代码审查结果的结构化展示。
5. 理解离线规则引擎和在线 LLM 模型的互补关系。
6. 掌握工程化部署中的测试、性能评估和错误处理。

本实验以命令行前端（CLI）+ 本地 Python HTTP 模型服务替代指导书中的 VS-Code 插件呈现层，经教师同意，功能等价。指导书要求的编辑器交互由以下 CLI 能力等价替代：从指定文件或 Git 工作区读取代码和修改内容、调用统一模型接口、在终端展示 Merge Prediction/审查意见/风险等级/定位信息，并保存历史记录。后端仍通过 HTTP 提供服务，保留前后端分离、模型可替换和工程部署三个核心目标。

二、方案与架构

2.1 总体架构

本实验采用前后端分离架构（架构图详见 README.md 或计划书第 2 节 Mermaid 流程图）。

CLI 前端 (reviewctl) 纯 HTTP 客户端，负责接收用户命令、构建请求、调用服务并渲染结果。不导入任何服务内部模块，不直接加载模型。

FastAPI 后端 提供 RESTful 接口，封装模型注册、审查编排、历史记录等功能。仅监听 127.0.0.1:8765。

模型层 包含离线规则分析器、实验六 LLM 适配器，以及实验二部署兼容 ML 适配器。

2.2 模块职责

- `schemas.py` —Pydantic 请求/响应模型，唯一的 HTTP 协议来源。
- `input_extractors.py` —文件读取与 Git diff 提取，支持 UTF-8 编码检测、二进制拒绝、内容截断。
- `risk_analyzer.py` —离线规则引擎，包含 6 条可解释规则。
- `adapters/` —三个模型适配器，实现统一抽象接口。
- `model_registry.py` —模型注册表，auto 选择顺序为：LLM → 部署版 RF → 部署版 SVM → rule-based。
- `review_service.py` —审查编排器，只依赖抽象适配器。
- `history_store.py` —JSONL 原子追加历史存储，默认不保存源代码。
- `cli.py` —argparse CLI，纯 HTTP 客户端。
- `server.py` —FastAPI 路由与异常映射。

2.3 安全边界

- 服务仅绑定 127.0.0.1，不对局域网公开。
- 输入不泄漏标签：本地审查输入只来自文件内容、Git diff、路径和本地元数据，不读取 merge 状态、review decision 等审查后字段。

- 默认最小化保存:历史只存输入摘要、SHA-256、统计量和审查结果;--store-source 才允许保存截断后的原文。
- API Key 从环境变量读取, 不写入代码、配置文件或日志。

三、实现过程

3.1 输入提取

支持两种输入模式:

- **单文件模式** (review --file <path>): 读取 UTF-8 源文件, 检测二进制、空文件和超大文件并给出明确错误。
- **Git diff 模式** (review --repo <dir> [--staged]): 通过 git diff 获取工作区或暂存区变更, 解析 unified diff 中的文件路径和新增行号。

代码截断策略: 超过 MAX_CONTENT_CHARS (默认 24000) 截断, 并在日志中记录原始长度。路径越界检测通过 Path.resolve() 实现。

3.2 离线规则分析器

规则模型是功能兜底, 不依赖外部 API。包含 6 条规则:

1. missing-test (权重 0.25): 代码文件修改但没有对应测试文件。
2. large-change (权重 0.20): 修改文件数 > 5 或变更行数 > 200。
3. config-or-dependency-change (权重 0.15): 修改配置文件或依赖声明。
4. public-api-change (权重 0.20): 函数/类签名变更在公开模块中。
5. todo-or-placeholder (权重 0.10): TODO/FIXME/HACK/XXX 标记。
6. debug-print (权重 0.10): print()、console.log 等调试输出。

风险分数 $R = \sum w_i \cdot 1[rule_i triggered]$, 合并概率 $P_{merge} = \max(0.05, 1.0 - R)$ 。此转换为启发式, 不可与实验五/六的分类指标进行横向性能比较。

3.3 模型集成

3.3.1 实验六 LLM 适配器

复用实验六 P8 “Strict Maintainer” prompt 策略，适配本地文件/diff 输入。LLM 请求格式：

- System prompt：严格的维护者审查角色，要求不默认预测 merged。
- User prompt：包含审查类型、文件列表、diff 内容、代码片段。
- JSON 解析：5 级回退（直接解析 → 代码块提取 → 正则提取 → 尾部逗号修复 → 首尾花括号提取）。

实验过程中已通过会话环境变量临时配置 LLM_API_KEY，并完成真实 API 调用；图中的 LLM 审查结果为实际响应。密钥未写入代码、配置文件、历史记录或报告，服务重启后需重新由环境变量提供。

3.3.2 实验二 ML 适配器

实验二原始 SVM 和 Random Forest 使用 61 维 PR 级特征，包含标题、正文、提交信息和仓库身份等本地 diff 无法稳定获得的元数据。因此原始模型保留为 incompatible，不以零值伪造输入。

为完成工程部署，基于实验二相同的 1397 条样本和固定训练/验证/测试划分，重训练了仅使用 Git diff 可计算特征的 45 维部署兼容版本：exp2-rf-deployable 和 exp2-svm-deployable。特征包括变更规模、文件类型、测试文件、AST、CFG 和缺失标志；训练集拟合的截断器与 StandardScaler 被封装进模型管线。

表 1:实验二部署兼容模型在原测试集上的结果

模型	Accuracy	Precision	Recall	F1	ROC-AUC
RF-deployable	0.7381	0.7410	0.9111	0.8173	0.7144
SVM-deployable	0.6381	0.7658	0.6296	0.6911	0.6983

部署版仅支持 Git diff 输入。图 4展示了 exp2-rf-deployable 的实际服务调用，证明模型不只处于已加载状态，而是完成了 predict_proba() 推理。

3.4 历史记录

采用 JSONL 格式，每次审查追加一行。写入使用临时文件 +os.replace 实现原子操作。默认不保存源代码（隐私保护）；--store-source 选项保存截断后的原文（最多 4000 字符 diff、2000 字符/文件），并输出警告。

3.5 终端呈现

默认使用 Rich 库渲染彩色表格，包含严重度图标和风险颜色。`--no-color` 退化为纯文本表格。`--format json` 输出完整 JSON，供其他工具（如 jq）消费。

四、测试与结果

4.1 功能测试

如表 2所示，全部功能测试通过。

表 2: 功能测试矩阵

编号	场景	操作	结果
T01	服务启动	serve 后访问/health	通过
T02	单文件审查	review -file	通过
T03	Git diff 审查	review -repo	通过（含 Git 仓库时）
T04	暂存区审查	-staged	
T05	LLM 不可用	无 key 指定 exp6-llm	通过（400/422）
T06	空 diff	干净工作区	通过（错误提示）
T07	非 Git 目录	review -repo 非仓库	通过（错误提示）
T08	结构化输出	-format json -no-color	通过
T09	历史记录	history 列表与详情	通过
T10	输入防护	二进制/超限/路径越界	通过

4.2 自动化测试

运行 `pytest -q` 命令，共 61 个测试全部通过。覆盖范围包括：

- Pydantic schema、离线规则、输入提取和历史存储。
- FastAPI 接口、CLI 命令路径和模型不可用的错误处理。
- 实验二部署兼容模型的特征维度和 Git diff 服务调用。

所有成功响应的 schema 校验率为 100%。

4.3 文件规模性能

使用固定内容、固定随机种子（seed=42）生成 100/500/1000/3000 行的 Python 文件，对每档连续运行 5 次 rule-based 审查，丢弃第一次（冷启动），记录剩余 4 次的中位数和 P95。

表 3:文件规模性能测试结果

文件规模	中位数（ms）	P95（ms）	均值（ms）
100 行	0.2	0.3	0.2
500 行	0.4	0.4	0.4
1000 行	0.8	0.8	0.8
3000 行	2.5	2.5	2.5

注:表中数值由脚本 `scripts/benchmark.ps1` 实际运行填充。运行命令: `.\scripts\benchmark.ps1`

4.4 实验结果截图




图 1: 服务健康状态与模型注册表

五、分析与局限

5.1 规则模型的局限

- 规则基于启发式模式匹配，不真正理解代码语义。
- 风险分数到合并概率的映射是线性的，不反映真实概率分布。
- 规则覆盖有限，无法检测复杂的逻辑缺陷、安全漏洞或性能问题。
- 行号定位依赖 unified diff 解析，在文件重命名或大范围重构时可能不准确。

```
(base) E:\latex\projects\experiments\experiment7>python -m src.cli review --file tests\fixtures\risky_example.py --model rule-based

=====
Code Review Report
=====
Request ID:      39854c14a20a
Model:           rule-based (rules)
Status:          success

Merge Prediction: not_merged
Probability:      55.00%
Risk Level:       medium
Confidence:        medium

Risk Factors:
- missing-test
- todo-or-placeholder
- debug-print

Review Comments (3):



|    | Severity | File                                 | Line | Rule                | Comment                                                                                              |
|----|----------|--------------------------------------|------|---------------------|------------------------------------------------------------------------------------------------------|
| ** | MAJOR    | E:\latex\projects\experiments\exp... | None | missing-test        | Changed code files without corresponding test changes. Please add or update tests for the modified b |
| !  | MINOR    | E:\latex\projects\experiments\exp... | 6    | todo-or-placeholder | TODO/FIXME/HACK markers found. Resolve or track these before merging.                                |
| !  | MINOR    | E:\latex\projects\experiments\exp... | 7    | debug-print         | Debug output (e.g. print(), console.log) found in production paths. Replace with proper logging or r |



Timing: extract=0.0ms model=0.3ms total=0.3ms
History: 20260716T150207-5730bf
=====
```

图 2: 规则模型的单文件审查结果

```
E:\latex\projects\experiments\experiment7>python -m src.cli review --file tests\fixtures\risky_example.py --model exp6-llm

=====
Code Review Report
=====
Request ID:      8920f0265686
Model:           exp6-llm (llm)
Status:          success

Merge Prediction: merged
Probability:      95.00%
Risk Level:       low
Confidence:        high

Review Comments (1):



|   | Severity | File                                        | Line | Rule | Comment                                                                                              |
|---|----------|---------------------------------------------|------|------|------------------------------------------------------------------------------------------------------|
| ● | NIT      | E:\latex\projects\experiments\experiment... | None | None | Unused imports 'os' and 'sys' are intentional as part of the 'risky' fixture. Consider adding a comm |



Timing: extract=0.0ms model=16336.0ms total=16336.0ms
History: 20260710T165628-46bc30
=====
```

图 3: 实验六 LLM 适配器的单文件审查结果

```
(base) E:\latex\projects\experiments\experiment7>python -m src.cli review --repo "E:\latex\projects\experiments\experiment7\results\demo_repo" --model exp2-rf-deployable --no-color

=====
Code Review Report
=====
Request ID:      dee7bf8ec317
Model:          exp2-rf-deployable (ml-rf)
Status:         success

Merge Prediction: merged
Probability:    57.21%
Risk Level:     medium
Confidence:     medium

Timing: extract=0.5ms model=63.2ms total=63.6ms
History: 20260716T152616-5c3af3
=====
```

图 4: 实验二部署兼容随机森林的 Git diff 审查

```
(base) E:\latex\projects\experiments\experiment7>python -m src.cli history --limit 5

Review History (5 total, showing 5):
```

History ID	Time	Model	Source	Prediction	Risk	Files	Changes	Time
20260716T150207-5730bf	20260716T150207	rule-based	file	not_merged	medium	1	+0/-0	0ms
20260710T170947-aef055	20260710T170947	no-such-model	file	?	?	1	+0/-0	0ms
20260710T170945-8ce8d0	20260710T170945	rule-based	file	merged	low	1	+0/-0	0ms
20260710T170944-bc1d42	20260710T170944	rule-based	file	not_merged	medium	1	+0/-0	0ms
20260710T170939-cfd956	20260710T170939	rule-based	file	merged	low	1	+0/-0	0ms

图 5: 审查历史列表

```
(base) E:\latex\projects\experiments\experiment7>python -m src.cli history --id 20260710T170944-bc1d42

History ID: 20260710T170944-bc1d42
Timestamp: 20260710T170944
Model: rule-based
Status: success
Source: file
Prediction: not_merged
Risk: medium
Files: 1
Changes: +0/-0
Time: 0ms

Review Comments (3):
[Major] E:\latex\projects\experiments\experiment7\tests\fixtures\risky_example.py:None - Changed code files without corresponding test changes. Please add or update tests for the modified behaviour.
[Minor] E:\latex\projects\experiments\experiment7\tests\fixtures\risky_example.py:6 - TODO/FIXME/HACK markers found. Resolve or track these before merging.
[Minor] E:\latex\projects\experiments\experiment7\tests\fixtures\risky_example.py:7 - Debug output (e.g. print(), console.log) found in production paths. Replace with proper logging or remove.

Risk Factors:
- missing-test
- todo-or-placeholder
- debug-print
```

图 6: 审查历史详情

Code Review Service

0.1.0 OAS 3.1

/openapi.json

default

GET /health Health

GET /v1/models List Models

POST /v1/reviews Create Review

GET /v1/history Get History

GET /v1/history/{history_id} Get History Detail

图 7: FastAPI 自动生成的接口文档


```
E:\latex\projects\experiments\experiment7>python -m pytest tests\ -q --tb=short
[100%]
===== warnings summary =====
C:\Users\20684\AppData\Roaming\Python\Python312\site-packages\fastapi\testclient.py:1
C:\Users\20684\AppData\Roaming\Python\Python312\site-packages\fastapi\testclient.py:1: StarletteDeprecationWarning: Us
ing 'httpx' with 'starlette.testclient' is deprecated; install 'httpx2' instead.
  from starlette.testclient import TestClient as TestClient # noqa
-- Docs: https://docs.pytest.org/en/stable/how-to/capture-warnings.html
61 passed, 1 warning in 15.69s
```

图 8: 自动化测试结果

```
(base) E:\latex\projects\experiments\experiment7>python scripts\benchmark.py
File Size Benchmark (rule-based adapter)

100 lines | median= 0.2ms P95= 0.3ms mean= 0.2ms
500 lines | median= 0.4ms P95= 0.4ms mean= 0.4ms
1000 lines | median= 0.8ms P95= 0.8ms mean= 0.8ms
3000 lines | median= 2.5ms P95= 2.5ms mean= 2.5ms

Saved: E:\latex\projects\experiments\experiment7\scripts\..\results\performance\file_size_benchmark.csv
```

图 9: 不同规模文件的规则模型性能测试

5.2 LLM 适配的局限

- 依赖外部 API，引入网络延迟和可用性风险。
- JSON 输出格式不稳定，需要多层回退解析。
- 上下文窗口限制（24000 字符截断），大 PR 可能丢失关键信息。
- API Key 仅临时存在于运行会话，未持久化保存；服务重启后需重新配置，且密钥不能写入代码、截图或报告。

5.3 ML 适配的局限

- 原始 61 维模型仍不适用于 CLI；部署版的 45 维特征集减少了 PR 元数据，指标不能与原始模型直接横向比较。
- 部署版仅支持 Git diff；单独文件没有新增/删除语义，不适合输入 ML 分类器。
- 特征分布差异：训练数据为 5 个大型开源项目的历史 PR，与本地任意文件/diff 的统计分布可能显著不同。

5.4 CLI 相比 IDE 的交互不足

- 无法实现编辑器内代码高亮和行内标注。
- 无实时/自动触发机制（需手动执行命令）。
- 结果展示在终端，与代码编辑上下文分离。
- 缺少 diff 可视化、问题导航和快速修复等 IDE 功能。

六、实验思考

6.1 为什么代码审查工具需要集成到 IDE 中？

代码审查工具集成到 IDE 中可以缩短反馈周期——开发者在编写代码的同时即可获得审查意见，无需切换到终端或其他工具。IDE 可以利用当前编辑器状态（打开的文件、未提交的 diff、光标位置等）提供上下文感知的审查。本实验的 CLI 方案验证了服务边界和协议设计，IDE 只需成为新的客户端——这也正是 HTTP 前后端分离架构的优势：替换前端不需要修改后端。

6.2 前后端分离架构相比本地部署有哪些优势？

- **模型独立升级：**更新模型版本、切换模型类型不影响客户端。
- **客户端轻量：**CLI/IDE 插件不依赖 PyTorch、Transformers 等重型框架。
- **统一协议：**所有客户端通过同一 HTTP 契约通信，便于测试和文档生成（OpenAPI）。
- **权限隔离：**API Key 只在服务端配置，不暴露给每个客户端。
- **代价：**需要启动服务进程、引入网络延迟和版本兼容问题。

6.3 如何提高插件的响应速度和用户体验？

- diff 和代码内容截断，减少传输和推理开销。
- 内容 SHA-256 缓存，避免重复审查相同内容。
- 异步/后台调用，不阻塞编辑器。
- 离线规则模型快速反馈（本实验 rule-based 典型耗时 <50ms）。
- LLM 超时设置和可解释错误信息，避免无限等待。
- 清晰的进度指示和模型状态显示。

6.4 插件部署过程中遇到了哪些工程问题？如何解决？

1. **Git 状态差异：**clean 工作区、未跟踪文件、二进制文件等边界情况需要专门的错误处理。解决：对每种情况分别检测并给出中文错误信息。
2. **二进制/超大文件：**文件大小检查、null 字节检测、编码异常捕获。解决：三层防护——文件大小上限、null 字节检测、UTF-8 解码异常处理。

3. **行号映射**: unified diff 到源文件行号的映射在复杂 diff 中可能不可靠。解决: 新增文件使用新文件行号; 无法可靠定位时设为 null。
4. **LLM JSON 不稳定**: 大语言模型的 JSON 输出偶尔包含尾部逗号、markdown 包裹或多余文本。解决: 5 级回退 JSON 解析器 (从实验六 llm_runner.py 迁移)。
5. **旧 ML 特征不匹配**: 原始 61 维 PR 模型含本地不可得元数据。解决: 保留原模型为 incompatible, 并以相同数据和划分重训练 45 维部署兼容模型。
6. **历史隐私**: 源代码默认写入历史会泄漏敏感信息。解决: 默认不保存源代码, 仅记录 SHA-256 摘要和统计量。
7. **fcntl 跨平台**: fcntl 是 Unix 专有模块, Windows 不可用。解决: 使用 os.replace (在 Windows 和 Unix 上均为原子操作)。

6.5 如果进一步完善该插件, 还可以增加哪些功能?

- **VSCode Extension**: 在已有 HTTP 协议上开发真正的 VSCode 插件, 实现编辑器内代码高亮、行内标注和问题导航。
- **GitHub PR 集成**: 支持在线 Pull Request 代码审查, 与 GitHub Checks API 集成。
- **增量审查**: 仅审查 diff 变更部分, 缓存未修改文件的审查结果。
- **模型版本评测**: 建立评测基准, 对比不同模型版本在相同输入上的表现。
- **自动修复建议**: 结合代码转换工具生成具体的修复补丁。
- **团队策略配置**: 允许项目配置自定义规则集、严重度阈值和审批策略。
- **多智能体协同**: 集成多个审查 Agent, 从不同维度 (安全、性能、风格、可维护性) 并行审查。

七、结论

本实验完成了命令行智能代码审查工具的全部核心功能:

- FastAPI 服务可启动, /health 和 /v1/models 可访问。
- CLI 能审查文件、Git diff, 并通过 HTTP 获得结构化结果。
- 离线 rule-based 模型完成 Merge Prediction 和评论生成, 不依赖外网即可演示。
- 审查历史可保存、列出、查看; 敏感代码正文默认不写入历史。

- 实验六 LLM 适配器已完成真实 API 调用，密钥仅通过临时环境变量提供且未持久化保存。
- 实验二原始模型的兼容性由特征契约 JSON 记录；45 维部署兼容 RF/SVM 已完成重训练并成功接入 Git diff 审查。
- 61 个自动化测试全部通过，覆盖 schema、提取器、分析器、历史存储、API 和部署版 ML 调用。
- 性能基准已实际执行，100 至 3000 行文件的规则模型中位耗时为 0.2 至 2.5ms。
- LaTeX 报告如实记录各项状态，不伪造模型预测或性能数据。

尚未实现的增强功能：VSCode 插件 UI、watch 监听模式、GitHub Actions annotation 格式输出。这些可在同一 HTTP 协议上作为新增客户端实现。

经教师同意以 CLI 等价替代 VSCode 插件要求，本实验验证了智能代码审查工具从算法模型到可运行工程系统的完整流程，实现了指导书要求的各项核心功能。